

MACHINE LEARNING

Analisis & Implementasi Decision Tree & Naive Bayes



Disusun Oleh:

Ahmad Febryan

(G1A024005)

Dosen Pengampu :

Ir. Arie Vatesia, S.T., M.T.I., Ph.D., IPP.

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS BENGKULU

2026

A. ANALISIS KONSEP

- 1. Jelaskan kapan Decision Tree lebih cocok digunakan dibanding Naive Bayes untuk kasus prediksi kelulusan ini. Beri 2 alasan.**

Jawab:

Decision Tree itu lebih cocok dipakai jika hubungan antara fitur dengan hasil kelulusan cukup susah dan tidak selalu saling bergantung secara sederhana. di kasus ini, faktor seperti IPK, Kehadiran, Jam_Belajar, Organisasi, dan juga Status_Beasiswa bisa memiliki pengaruh yang berbeda-beda terhadap kelulusan. Decision Tree ini dapat membuat aturan seperti *jika IPK tinggi dan kehadiran tinggi maka kemungkinan lulus tepat waktu lebih besar*, sehingga pola tersebut lebih mudah dipahami. Alasan keduanya adalah Decision Tree tidak membutuhkan asumsi kalau setiap fitur saling independen seperti pada Naive Bayes. Selain itu, hasil Decision Tree lebih mudah dijelaskan karena bentuknya berupa percabangan keputusan.

- 2. Asumsi "independen" di Naive Bayes. Sebutkan 2 pasang fitur di dataset yang kemungkinan melanggar asumsi ini dan jelaskan kenapa.**

Jawab:

Naive Bayes ada asumsi bahwa setiap fitur bersifat independen satu sama lain terhadap kelas yang diprediksi. Artinya, model menganggap satu fitur tidak ada hubungan dengan fitur lainnya. di dataset ini, salah satu pasangan fitur yang kemungkinan melanggar asumsi tersebut itu IPK dan Jam_Belajar. Mahasiswa yang memiliki jam belajar lebih banyak kemungkinan memiliki IPK yang lebih tinggi, sehingga kedua fitur tersebut dapat saling berhubungan. Pasangan lainnya yaitu Status_Beasiswa dan Penghasilan_Ortu. Mahasiswa yang berasal dari keluarga dengan penghasilan orang tua lebih rendah memiliki kemungkinan lebih besar mendapatkan beasiswa. Dengan demikian, kedua fitur tersebut tidak sepenuhnya independen. Walaupun Naive Bayes tetap dapat digunakan pas terdapat hubungan antarfitur, asumsi independensi yang tidak terpenuhi dapat memengaruhi hasil prediksi model.

- 3. Apa risiko overfitting pada Decision Tree di dataset ini? Bagaimana cara mengatasinya?**

Jawab:

Overfitting dapat terjadi ketika Decision Tree terlalu mengikuti pola yang terdapat pada data training, termasuk pola yang sebenarnya hanya kebetulan atau noise. Ini bisa

terjadi terutama pada Decision Tree dengan `max_depth=None`, karena tree dapat terus bercabang dan bahkan membuat aturan berdasarkan data yang sangat spesifik. Akibatnya, model bisa memiliki hasil yang sangat baik pada data training tetapi performanya menurun ketika digunakan pada data mahasiswa baru.

Untuk mengatasi overfitting, salah satu cara yang dapat digunakan adalah membatasi percabangan tree dengan `max_depth`, misalnya `max_depth=3`. Selain itu, dapat digunakan teknik seperti `min_samples_split`, `min_samples_leaf`, atau `pruning` untuk membatasi kompleksitas pohon. Dalam tugas ini, perbandingan antara Decision Tree dengan `max_depth=3` dan `max_depth=None` juga dapat digunakan untuk melihat pengaruh kedalaman pohon terhadap performa model.

B. Implementasi & Evaluasi

1. Preprocessing

Missing value di fitur numerik seperti IPK, Kehadiran, Jam_Belajar itu diimputasi dengan median masing-masing kolom karena lebih tahan terhadap outlier dibanding rata-rata, sementara missing value pada fitur kategorik diimputasi dengan modus (nilai paling sering muncul). Seluruh fitur kategorik kemudian di-encode menggunakan Label Encoding agar dapat diproses oleh scikit-learn, dan data dibagi menjadi data latih dan data uji dengan rasio 80:20 menggunakan stratifikasi pada target agar proporsi kelas Ya/Tidak tetap terjaga di kedua subset.

Model	Akurasi	Precision	Recall	F1-Score
Decision Tree (<code>max_depth=3</code>)	0.670	0.671	0.919	0.776
Decision Tree (<code>max_depth=None</code>)	0.490	0.585	0.613	0.598
Gaussian Naive Bayes	0.670	0.693	0.839	0.759

2. Modeling


Tiga model dilatih pada data latih yang sama: Decision Tree dengan `max_depth=3` (dibatasi/pruned), Decision Tree dengan `max_depth=None` (tidak dibatasi), dan Gaussian Naive Bayes.

3. Evaluasi Tabel Perbandingan Metrik


Decision Tree (max_depth=3) dan Gaussian Naive Bayes menghasilkan akurasi yang identik yaitu 0.67, namun Naive Bayes unggul tipis pada precision dan Decision Tree (depth=3) unggul pada recall kelas Ya. Decision Tree tanpa batas kedalaman jelas paling buruk pada seluruh metrik.

4. Visualisasi


Confusion matrix ketiga model:



Pohon keputusan (max_depth=3):



Perbandingan metrik dalam bentuk bar chart, serta feature importance Decision Tree (IPK dan Kehadiran tampak sebagai dua fitur paling berpengaruh, sejalan dengan intuisi akademik bahwa performa akademik dan keterlibatan kelas adalah prediktor utama kelulusan tepat waktu):



5. Analisis Error

Contoh diambil dari Decision Tree (max_depth=None) karena model yang ini paling menunjukkan gejala overfitting:

IPK	Kehadiran	Jam Belajar	Organisasi	Penghasilan Ortu	Aktual	Prediksi
3.24	64.1	26.0	Tidak Aktif	Tinggi	Tidak	Ya
3.53	85.3	27.4	Aktif	Menengah	Tidak	Ya
2.55	82.1	25.3	Tidak Aktif	Tinggi	Tidak	Ya
3.05	82.9	19.2	Tidak Aktif	Menengah	Ya	Tidak
3.66	74.6	12.3	Aktif	Menengah	Ya	Tidak

Tiga baris pertama diprediksi Ya padahal aktualnya itu Tidak: ketiganya ini memiliki IPK relatif tinggi sekitar 2.55–3.53 tapi kehadirannya menengah sekitar 64–85% dan jam belajar cukup tinggi sekitar 25–27 jam, kombinasi yang di data latih kebetulan banyak berujung Ya, sehingga pohon yang tidak dibatasi menghafal pola spesifik tersebut alih-alih pola umum, dan gagal menangkap faktor lain yang membuat mahasiswa ini sebenarnya tidak

lulus tepat waktu. Dua baris terakhir sebaliknya diprediksi Tidak padahal aktualnya Ya, keduanya memiliki IPK cukup tinggi 3.05 dan 3.66 tetapi jam belajarnya tergolong rendah 12–19 jam, model tanpa batas kedalaman membentuk cabang yang sangat spesifik berdasar kombinasi jam belajar rendah dari sampel latih tertentu, yang ternyata tidak berlaku umum. Pola ini mengonfirmasi bahwa error terjadi karena pohon yang dalam mempelajari kombinasi fitur yang terlalu spesifik dari data latih, bukan sinyal yang benar-benar prediktif.

C. Rekomendasi & Etika

1. Rekomendasi Model

Berdasarkan tabel metrik di Bagian B, Decision Tree (max_depth=None) langsung dieliminasi karena overfitting dan performa uji terendah. Antara Decision Tree (max_depth=3) dan Gaussian Naive Bayes, akurasi sama yakni 0.67, tetapi macro-average F1-score Naive Bayes sedikit lebih tinggi sekitar 0.62 berbanding 0.58 karena Naive Bayes lebih baik mengenali kelas minoritas Tidak lulus tepat waktu (recall 0.39 vs 0.26). Dalam konteks ini, mendeteksi mahasiswa yang berisiko TIDAK lulus tepat waktu justru lebih penting agar bimbingan akademik atau konseling bisa dilakukan lebih dini, sehingga rekomendasi utama adalah Gaussian Naive Bayes sebagai model prediksi risiko, didampingi Decision Tree (max_depth=3) sebagai alat bantu interpretasi/komunikasi kepada dosen wali karena aturan percabangannya mudah dijelaskan secara visual. Model sebaiknya tidak dipakai sebagai satu-satunya dasar keputusan, melainkan sebagai alat bantu (decision support), mengingat akurasi keduanya baru berkisar 67% dan masih memerlukan data atau fitur tambahan misalnya nilai per semester, keterlibatan magang, atau alasan cuti akademik supaya lebih baik.

2. Bias & Etika

Fitur Penghasilan_Ortu dan Jenis_Kelamin berpotensi menjadi proxy diskriminasi. Kalau model dipakai untuk menyaring penerima beasiswa, mahasiswa dari keluarga berpenghasilan rendah yang kehadirannya rendah karena harus bekerja paruh waktu bisa diprediksi berisiko tidak lulus tepat waktu dan justru gagal mendapat beasiswa padahal mereka adalah kelompok yang paling membutuhkan bantuan finansial tersebut, sehingga model dapat memperlebar kesenjangan alih-alih menguranginya. Demikian pula, jika data historis mengandung bias gender misalnya mahasiswa perempuan di prodi tertentu secara historis dicatat lebih sering cuti karena alasan non-akademik yang tidak tercatat, model

bisa belajar asosiasi keliru antara Jenis_Kelamin dan risiko kelulusan, padahal hubungan itu semu.

Mitigasi yang dapat dilakukan: 1) mengecualikan Jenis_Kelamin sebagai fitur prediktif langsung, atau menjadikannya hanya sebagai variabel pemantauan, bukan input model; 2) melakukan audit fairness secara berkala dengan mengukur metrik per kelompok misalnya recall/precision terpisah untuk tiap kategori Penghasilan_Ortu dan Jenis_Kelamin buat memastikan tidak ada disparate impact; 3) menjadikan output model sebagai salah satu masukan bagi tim akademik manusiawi, bukan penentu tunggal kelayakan beasiswa; 4) transparan kepada mahasiswa mengenai faktor apa saja yang memengaruhi prediksi, serta menyediakan mekanisme banding manual bila mahasiswa merasa diprediksi secara tidak adil.

3. Simulasi: IPK Tinggi, Kehadiran Rendah

Untuk kasus simulasi mahasiswa dengan $IPK=3.8$ yang tergolong tinggi namun Kehadiran cuma 55% tergolong rendah, hasil model di Bagian B adalah sebagai berikut: Decision Tree ($max_depth=3$) memprediksi Ya (lulus tepat waktu) dengan probabilitas 0.875, sedangkan Gaussian Naive Bayes juga memprediksi Ya namun dengan probabilitas jauh lebih tipis, yaitu 0.529 yang nyaris seimbang dengan Tidak 0.471.

Perbedaan tingkat keyakinan ini terjadi karena cara kedua algoritma menggabungkan bukti dari beberapa fitur berbeda secara mendasar. Decision Tree mengikuti jalur percabangan bersyarat: begitu IPK mahasiswa berada di atas ambang tertentu pada cabang kanan pohon, node berikutnya mengecek Kehadiran, dan pada kombinasi spesifik IPK sangat tinggi sekitar >3.545 meski Kehadiran di kisaran 55–70%, mayoritas sampel latih pada daun tersebut tetap berlabel Ya, sehingga pohon mengizinkan IPK yang sangat tinggi mengompensasi kehadiran yang rendah secara hampir mutlak. Naive Bayes sebaliknya mengalikan likelihood tiap fitur secara independen: nilai Kehadiran=55% jauh dari rata-rata kelompok Ya pada data latih, sehingga likelihood untuk kelas Ya ditekan cukup signifikan oleh fitur ini sendiri, dan hanya sedikit lebih besar dibanding likelihood kelas Tidak setelah dikalikan dengan seluruh fitur lain menghasilkan probabilitas akhir yang jauh lebih ragu-ragu meskipun keputusan akhirnya kebetulan sama. Jadi ini memperlihatkan secara nyata bagaimana asumsi independensi Naive Bayes bisa membuatnya kurang sensitif terhadap kombinasi atau interaksi fitur dibanding Decision Tree.

Kesimpulan

Decision Tree dan Naive Bayes sama-sama mampu memprediksi kelulusan tepat waktu dengan akurasi sekitar 67% di dataset ini, tapi keduanya memiliki karakteristik yang saling melengkapi: Decision Tree unggul dalam interpretabilitas dan menangkap interaksi antar fitur, sementara Naive Bayes sedikit lebih baik dalam mengenali kelompok mahasiswa yang berisiko.