

MACHINE LEARNING

Analisis & Implementasi Decision Tree & Naive Bayes



Disusun Oleh:

Yudhistira Rizky Ramadhan

(G1A024079)

Dosen Pengampu :

Ir. Arie Vatesia, S.T., M.T.I., Ph.D., IPP.

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS BENGKULU

2026

A. ANALISIS KONSEP

- 1. Jelaskan kapan Decision Tree lebih cocok digunakan dibanding Naive Bayes untuk kasus prediksi kelulusan ini. Beri 2 alasan.**

Jawab:

1. Bisa menangkap interaksi antar-fitur (hubungan non-linear): Di kasus prediksi kelulusan, variabel saling memengaruhi satu sama lain. Contohnya, efek dari Kehadiran rendah akan berdampak beda pada mahasiswa dengan IPK tinggi dibanding mahasiswa dengan IPK pas-pasan. Decision Tree mampu membuat percabangan bersyarat (if-then) untuk kombinasi seperti ini, sedangkan Naive Bayes menganggap tiap fitur berdiri sendiri tanpa memedulikan hubungan antar-variabel.
2. Hasilnya mudah diinterpretasikan oleh pihak akademis: Decision Tree menghasilkan alur keputusan visual yang jelas. Dosen wali atau tim akademik bisa langsung paham alasan logis di balik suatu prediksi (misal: "Jika IPK ≤ 2.66 DAN Kehadiran $\leq 87.3\%$ $\rightarrow$ Berisiko"). Sementara Naive Bayes cuma mengeluarkan kalkulasi angka probabilitas yang kurang intuitif kalau mau dijelaskan ke orang awam.

- 2. Asumsi "independen" di Naive Bayes. Sebutkan 2 pasang fitur di dataset yang kemungkinan melanggar asumsi ini dan jelaskan kenapa.**

Jawab:

Fitur 1: IPK dan Jam_Belajar (atau Kehadiran)

Alasan: Secara ilmiah dan praktis, lama waktu belajar serta keaktifan hadir di kelas berkorelasi langsung dengan tingkat pemahaman materi yang berujung pada nilai IPK. Karena Jam_Belajar memengaruhi tinggi-rendahnya IPK, kedua fitur ini tidak saling bebas (terikat).

Fitur 2: Organisasi dan Jam_Belajar (atau Kehadiran)

Alasan: Kesibukan berorganisasi biasanya menyita waktu luang mahasiswa. Mahasiswa yang sangat aktif di organisasi cenderung punya alokasi Jam_Belajar mandiri atau tingkat Kehadiran yang terpengaruh dibanding mahasiswa yang tidak aktif, sehingga kedua fitur ini saling berkaitan.

- 3. Apa risiko overfitting pada Decision Tree di dataset ini? Bagaimana cara mengatasinya?**

Jawab:

Risiko Overfitting: Jika pohon dibiarkan tumbuh tanpa batas (`max_depth=None`), model bakal "menghafal" seluruh noise dan pola yang sangat spesifik pada data latih (misalnya menghafal kasus anomali di mana mahasiswa dengan Jam_Belajar rendah tapi IPK tinggi tetap lulus). Akibatnya, performa model kelihatan bagus di data latih, tapi bakal anjlok saat menguji data baru/data uji (seperti pada eksperimen di mana akurasi jatuh ke angka 0.49).

Cara Mengatasinya:

- **Menerapkan Pruning (Pemangkasan Pohon):** Membatasi kedalaman pohon sejak awal (misalnya menyetel `max_depth=3`) atau mengatur batasan sampel seperti `min_samples_split` dan `min_samples_leaf` agar pohon tidak membentuk cabang yang terlalu detail.
- **Menggunakan Cross-Validation:** Menerapkan k-fold cross-validation saat melatih dan tuning hyperparameter untuk memastikan model bergeneralisasi dengan baik di berbagai pembagian data.
- **Beralih ke Metode Ensemble (Random Forest):** Menggabungkan hasil prediksi dari banyak pohon keputusan acak untuk menekan varians dan mencegah model berfokus pada satu jalur percabangan saja.

B. Implementasi & Evaluasi

1. Preprocessing

Missing value di fitur numerik seperti IPK, Kehadiran, Jam_Belajar itu diimputasi dengan median masing-masing kolom karena lebih tahan terhadap outlier dibanding rata-rata, sementara missing value pada fitur kategorik diimputasi dengan modus (nilai paling sering muncul). Seluruh fitur kategorik kemudian di-encode menggunakan Label Encoding agar dapat diproses oleh scikit-learn, dan data dibagi menjadi data latih dan data uji dengan rasio 80:20 menggunakan stratifikasi pada target agar proporsi kelas Ya/Tidak tetap terjaga di kedua subset.

2. Modeling


Tiga model dilatih pada data latih yang sama: Decision Tree dengan `max_depth=3` (dibatasi/pruned), Decision Tree dengan `max_depth=None` (tidak dibatasi), dan Gaussian Naive Bayes.

3. Evaluasi Tabel Perbandingan Metrik


Decision Tree (max_depth=3) dan Gaussian Naive Bayes menghasilkan akurasi yang identik yaitu 0.67, namun Naive Bayes unggul tipis pada precision dan Decision Tree (depth=3) unggul pada recall kelas Ya. Decision Tree tanpa batas kedalaman jelas paling buruk pada seluruh metrik.

4. Visualisasi


Confusion matrix ketiga model:



Pohon keputusan (max_depth=3):



Perbandingan metrik dalam bentuk bar chart, serta feature importance Decision Tree (IPK dan Kehadiran tampak sebagai dua fitur paling berpengaruh, sejalan dengan intuisi akademik bahwa performa akademik dan keterlibatan kelas adalah prediktor utama kelulusan tepat waktu):



5. Analisis Error

Contoh diambil dari Decision Tree (max_depth=None) karena model yang ini paling menunjukkan gejala overfitting:

IPK	Kehadiran	Jam Belajar	Organisasi	Penghasilan Ortu	Aktual	Prediksi
3.24	64.1	26.0	Tidak Aktif	Tinggi	Tidak	Ya
3.53	85.3	27.4	Aktif	Menengah	Tidak	Ya
2.55	82.1	25.3	Tidak Aktif	Tinggi	Tidak	Ya
3.05	82.9	19.2	Tidak Aktif	Menengah	Ya	Tidak
3.66	74.6	12.3	Aktif	Menengah	Ya	Tidak

Tiga baris pertama diprediksi Ya padahal aktualnya itu Tidak: ketiganya ini memiliki IPK relatif tinggi sekitar 2.55–3.53 tapi kehadirannya menengah sekitar 64–85% dan jam belajar cukup tinggi sekitar 25–27 jam, kombinasi yang di data latih kebetulan banyak berujung Ya, sehingga pohon yang tidak dibatasi menghafal pola spesifik tersebut alih-alih pola umum, dan gagal menangkap faktor lain yang membuat mahasiswa ini sebenarnya tidak

lulus tepat waktu. Dua baris terakhir sebaliknya diprediksi Tidak padahal aktualnya Ya, keduanya memiliki IPK cukup tinggi 3.05 dan 3.66 tetapi jam belajarnya tergolong rendah 12–19 jam, model tanpa batas kedalaman membentuk cabang yang sangat spesifik berdasar kombinasi jam belajar rendah dari sampel latih tertentu, yang ternyata tidak berlaku umum. Pola ini mengonfirmasi bahwa error terjadi karena pohon yang dalam mempelajari kombinasi fitur yang terlalu spesifik dari data latih, bukan sinyal yang benar-benar prediktif.

C. Rekomendasi & Etika

1. Rekomendasi Model

Berdasarkan tabel metrik di Bagian B, Decision Tree (max_depth=None) langsung dieliminasi karena overfitting dan performa uji terendah. Antara Decision Tree (max_depth=3) dan Gaussian Naive Bayes, akurasi sama yakni 0.67, tetapi macro-average F1-score Naive Bayes sedikit lebih tinggi sekitar 0.62 berbanding 0.58 karena Naive Bayes lebih baik mengenali kelas minoritas Tidak lulus tepat waktu (recall 0.39 vs 0.26). Dalam konteks ini, mendeteksi mahasiswa yang berisiko TIDAK lulus tepat waktu justru lebih penting agar bimbingan akademik atau konseling bisa dilakukan lebih dini, sehingga rekomendasi utama adalah Gaussian Naive Bayes sebagai model prediksi risiko, didampingi Decision Tree (max_depth=3) sebagai alat bantu interpretasi/komunikasi kepada dosen wali karena aturan percabangannya mudah dijelaskan secara visual. Model sebaiknya tidak dipakai sebagai satu-satunya dasar keputusan, melainkan sebagai alat bantu (decision support), mengingat akurasi keduanya baru berkisar 67% dan masih memerlukan data atau fitur tambahan misalnya nilai per semester, keterlibatan magang, atau alasan cuti akademik supaya lebih baik.

2. Bias & Etika

Fitur Penghasilan_Ortu dan Jenis_Kelamin berpotensi menjadi proxy diskriminasi. Kalau model dipakai untuk menyaring penerima beasiswa, mahasiswa dari keluarga berpenghasilan rendah yang kehadirannya rendah karena harus bekerja paruh waktu bisa diprediksi berisiko tidak lulus tepat waktu dan justru gagal mendapat beasiswa padahal mereka adalah kelompok yang paling membutuhkan bantuan finansial tersebut, sehingga model dapat memperlebar kesenjangan alih-alih menguranginya. Demikian pula, jika data historis mengandung bias gender misalnya mahasiswa perempuan di prodi tertentu secara historis dicatat lebih sering cuti karena alasan non-akademik yang tidak tercatat, model

bisa belajar asosiasi keliru antara Jenis_Kelamin dan risiko kelulusan, padahal hubungan itu semu.

Mitigasi yang dapat dilakukan: 1) mengecualikan Jenis_Kelamin sebagai fitur prediktif langsung, atau menjadikannya hanya sebagai variabel pemantauan, bukan input model; 2) melakukan audit fairness secara berkala dengan mengukur metrik per kelompok misalnya recall/precision terpisah untuk tiap kategori Penghasilan_Ortu dan Jenis_Kelamin buat memastikan tidak ada disparate impact; 3) menjadikan output model sebagai salah satu masukan bagi tim akademik manusiawi, bukan penentu tunggal kelayakan beasiswa; 4) transparan kepada mahasiswa mengenai faktor apa saja yang memengaruhi prediksi, serta menyediakan mekanisme banding manual bila mahasiswa merasa diprediksi secara tidak adil.

3. Simulasi: IPK Tinggi, Kehadiran Rendah

Untuk kasus simulasi mahasiswa dengan IPK=3.8 yang tergolong tinggi namun Kehadiran cuma 55% tergolong rendah, hasil model di Bagian B adalah sebagai berikut: Decision Tree (max_depth=3) memprediksi Ya (lulus tepat waktu) dengan probabilitas 0.875, sedangkan Gaussian Naive Bayes juga memprediksi Ya namun dengan probabilitas jauh lebih tipis, yaitu 0.529 yang nyaris seimbang dengan Tidak 0.471.

Perbedaan tingkat keyakinan ini terjadi karena cara kedua algoritma menggabungkan bukti dari beberapa fitur berbeda secara mendasar. Decision Tree mengikuti jalur percabangan bersyarat: begitu IPK mahasiswa berada di atas ambang tertentu pada cabang kanan pohon, node berikutnya mengecek Kehadiran, dan pada kombinasi spesifik IPK sangat tinggi sekitar >3.545 meski Kehadiran di kisaran 55–70%, mayoritas sampel latih pada daun tersebut tetap berlabel Ya, sehingga pohon mengizinkan IPK yang sangat tinggi mengompensasi kehadiran yang rendah secara hampir mutlak. Naive Bayes sebaliknya mengalikan likelihood tiap fitur secara independen: nilai Kehadiran=55% jauh dari rata-rata kelompok Ya pada data latih, sehingga likelihood untuk kelas Ya ditekan cukup signifikan oleh fitur ini sendiri, dan hanya sedikit lebih besar dibanding likelihood kelas Tidak setelah dikalikan dengan seluruh fitur lain menghasilkan probabilitas akhir yang jauh lebih ragu-ragu meskipun keputusan akhirnya kebetulan sama. Jadi ini memperlihatkan secara nyata bagaimana asumsi independensi Naive Bayes bisa membuatnya kurang sensitif terhadap kombinasi atau interaksi fitur dibanding Decision Tree.

Kesimpulan

Decision Tree dan Naive Bayes sama-sama mampu memprediksi kelulusan tepat waktu dengan akurasi sekitar 67% di dataset ini, tapi keduanya memiliki karakteristik yang saling melengkapi: Decision Tree unggul dalam interpretabilitas dan menangkap interaksi antar fitur, sementara Naive Bayes sedikit lebih baik dalam mengenali kelompok mahasiswa yang berisiko.